

Análisis Estadístico

Bootstrap

San Andrés

May 30, 2022

Cálculo numérico del EMV

Example

Sea $X_1, \dots, X_n \sim \Gamma(\alpha, \lambda)$ esto es

$$f(x; \alpha, \lambda) = \frac{1}{\Gamma(\alpha)} \lambda^\alpha x^{\alpha-1} e^{-\lambda x}, \quad 0 \leq x < +\infty.$$

- 1 Encontrar los estimadores de momentos para α y λ .
- 2 Definir en R una función que calcula el logaritmo de la verosimilitud de (α, λ) para una muestra dada.
- 3 Hallar ambos estimadores para los datos del dataset `gamma-arrivals.csv`.
- 4 Graficar el histograma de la muestra y las densidades estimadas.
- 5 Para $\alpha = 2$ y $\lambda = 0.5$ Calcular 1000 muestras de tamaño $n = 20$ y graficar los histogramas de ambos estimadores en cada muestra.

Sugerencias: Utilizar las funciones `gamma()`, `rgamma()` y `optim()`.

Función de distribución empírica

Sea X_1, \dots, X_n una muestra aleatoria con distribución F llamamos distribución empírica

$$F_n(t) = \frac{1}{n} \sum_{i=1}^n I_{(-\infty, t]}(X_i).$$

Es decir, para cada t

$F_n(t) =$ Proporción de la muestra menor o igual a t .

Función de distribución empírica

Propiedades

Para cada t sabemos la distribución de $F_n(t)$.

$$F_n(t) \sim \text{Bi}(n, P(X \leq t)).$$

Además la distribución empírica es la distribución acumulada de la variable aleatoria Y que tiene como puntos de masa los valores de la muestra:

$$p_Y(t) = \frac{\#\{x_i = t\}}{n}.$$

Distribución empírica

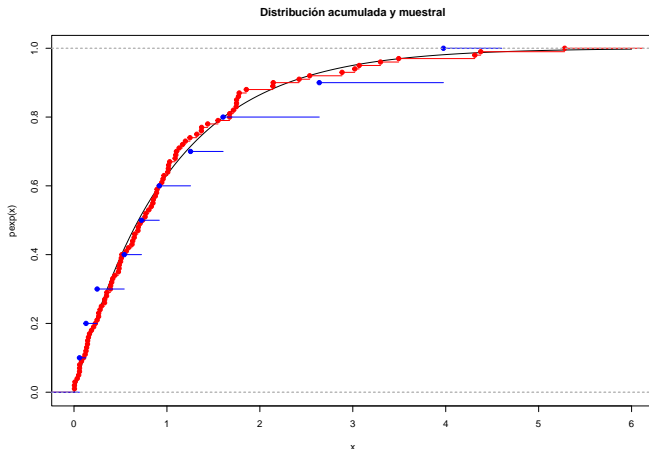


Figure: Función acumulada de $X \sim \text{Exp}(1)$ y distribuciones empíricas para $n = 10$ (azul) y $n = 100$ (rojo)

Distribución empírica - Método de plug-in

Método de plug in

A partir de F_n se puede estimar parametros de F .

$$\theta = T(F) \implies \hat{\theta} = T(F_n).$$

- $\widehat{E(X)} = E(Y) = \frac{1}{n} \sum_{i=1}^n X_i$
- $\widehat{Var(X)} = Var(Y) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$.
- $F^{-1}(0.9) = F_n^{-1}(0.9)$

A diferencia de momentos y máxima verosimilitud no necesitamos un modelo paramétrico.

Estimación de la función de distribución

Example (Distribución de una Exponencial)

Estimar de dos maneras la función de distribución acumulada de esta muestra $X_1, \dots, X_{10} \sim \text{Exp}(\lambda)$.

2.64, 0.13, 0.73, 1.60, 0.92, 1.25, 0.06, 0.25, 0.54, 3.98

Como $F(t) = 1 - e^{-\lambda t}$ entonces $\hat{F} = 1 - e^{-\hat{\lambda}t}$

Estimación de la función de distribución

Example (Distribución de una Exponencial)

Estimar de dos maneras la función de distribución acumulada de esta muestra $X_1, \dots, X_{10} \sim \text{Exp}(\lambda)$.

2.64, 0.13, 0.73, 1.60, 0.92, 1.25, 0.06, 0.25, 0.54, 3.98

Como $F(t) = 1 - e^{-\lambda t}$ entonces $\hat{F} = 1 - e^{-\hat{\lambda}t}$

Distribución empírica

Example

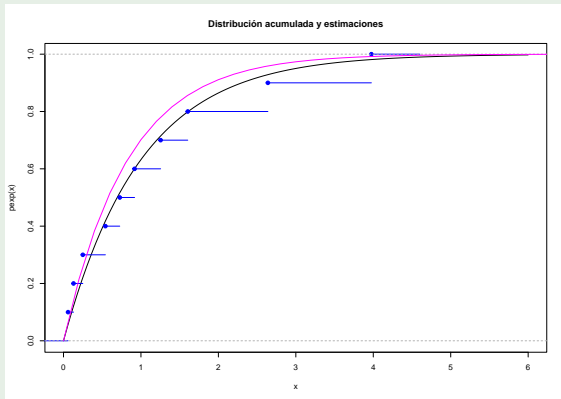


Figure: Función acumulada de $X \sim \text{Exp}(1)$ y dos estimaciones de la muestra

Bootstrap

Bootstrap es una herramienta que permite estimar parámetros de la distribución de un estimador utilizando únicamente la información de la muestra.

$$X_1, \dots, X_n \sim F$$

$$\hat{\theta} = g(X_1, \dots, X_n)$$

Como sabemos $\hat{\theta}$ es una variable aleatoria con una distribución.

$$\hat{\theta} \sim G = g(F)$$

La distribución del estimador depende de la distribución F y de la función g que define al estimador.

¿Cómo estimamos un parámetro $T(G)$? e.g

$$E(\hat{\theta}) \quad SD(\hat{\theta}) \quad G^{-1}(0.9).$$

Estimación de un parámetro de la distribución del estimador

- 1 Estimamos el parámetro por plug-in:

$$\widehat{T(\hat{G})} = T(\hat{G}).$$

- 2 Donde $\hat{G} = g(\hat{F})$.
¿Cómo llevamos esto a la práctica?

Estimación del desvío de un estimador

- 1 x_1, x_2, \dots, x_n es la realización de una muestra de distribución F .
- 2 \hat{F} es la estimación de F (por cualquier metodología)
- 3 Sorteamos una nueva muestra $x_1^*, x_2^*, \dots, x_n^* \sim \hat{F}$.
- 4 Calculamos $\hat{\theta}^* = g(x_1^*, \dots, x_n^*)$
- 5 Repetimos 3 y 4 N_{boot} veces para obtener una muestra

$$\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_{N_{boot}}^* \sim \hat{G}$$

- 6 Estimamos el parámetro de interés con la muestra bootstrap

Bootstrap

Por ejemplo

$$\widehat{E(\hat{\theta})} = \frac{1}{n} \sum_{j=1}^{N_{boot}} \hat{\theta}_j^*$$

$$\widehat{SD(\hat{\theta})} = \sqrt{\frac{1}{n} \sum_{j=1}^{N_{boot}} (\hat{\theta}_j^* - \widehat{\bar{\theta}}^*)^2}$$

$$\widehat{G^{-1}(0.9)} = \text{cuantil}(0.9) \{ \hat{\theta}_1^*, \dots, \hat{\theta}_{N_{boot}}^* \}$$

Bootstrap

Bootstrap por resampleo

Para generar una muestra con distribución F_n basta sortear con reposición los elementos de la muestra. (¿Por qué?)


Bootstrap parametrico

Si $F = F_\lambda$ y tenemos $\hat{\lambda}$ un estimador del parámetro podemos generar muestra bajo la distribución $F_{\hat{\lambda}}$.

Bootstrap

Example

Old Faithful Se registrarios las duraciones en segundos de 272 erupciones consecutivas del geyser Old Faithful del parque nacional Yellowstone.



Example

Old Faithfull Vamos a estimar esperanza, desvío y cuantil 0.9.
Cómo no tenemos un modelo paramétrico hacemos bootstrap por resampleo

- 1 Datos: x_1, \dots, x_{272}
- 2 Mediana: $x_{mediana} = 4$
- 3 Generamos una muestra bootstrap $x_1^*, \dots, x_{272}^* \sim F_n$.
- 4 Calculamos $x_{mediana}^*$
- 5 Repetimos 3 y 4 $N_{boot} = 1000$ veces.
- 6 Calculamos los estimadores plug-in de la muestra.

Example

Simulación Estimar el desvío estándar mediante bootstrap de los estimadores de máxima verosimilitud y momentos con los datos de `Gamma-arrivals.csv`