

APRENDIZAJE NO SUPERVISADO

Maestría en Ciencia de Datos

Lucas Fernández Piana

Primavera 2022

Universidad de San Andrés

APRENDIZAJE SUPERVISADO...

EJEMPLO: REGRESIÓN LINEAL




Figura 1: Regresión simple

EJEMPLO: SPLINES




Figura 2: Splines

EJEMPLO: CLASIFICACIÓN




Figura 3: Clasificación binaria.

EJEMPLO: CLASIFICACIÓN




Figura 4: Clasificación binaria.

EJEMPLO: CLASIFICACIÓN BINARIA IMÁGENES



Figura 5: Cat or dog challenge

EJEMPLO: CLASIFICACIÓN BINARIA IMÁGENES

$f(\text{img_dog}) \rightarrow \text{dog}$

$f(\text{img_cat}) \rightarrow \text{cat}$

Figura 6: cute algorithm

El aprendizaje supervisado se podría resumir en la siguiente metodología predecir los valores una variable o vector de *respuestas*, $Y = (Y_1, \dots, Y_l)$, dado un vector predictor $X = (X_1, \dots, X_p)$.

Dependiendo de la naturaleza de Y podemos determinar las dos clases más conocidas de problemas.

- Y discreto \rightarrow “**Clasificación**”.
- Y continua \rightarrow “**Regresión**”.

FORMALMENTE

Consideremos dos espacio \mathcal{X} (input) y \mathcal{Y} (output). Asumimos que el par $(X, Y) \in \mathcal{X} \times \mathcal{Y}$ son elementos aleatorios (variables, vectores, funciones) con distribución conjunta y desconocida P .

Sea $L : \mathcal{Y} \rightarrow \mathbb{R}$ decimos que es una *función de pérdida* si cumple:

- $L(y_1, y_2) = 0 \iff y_1 = y_2$.
- L es no negativa.

El objetivo es construir una función $g : \mathcal{X} \rightarrow \mathcal{Y}$ tal que $g(X)$ predice a Y . Es decir,

El objetivo es construir una función $g : \mathcal{X} \rightarrow \mathcal{Y}$ tal que $g(X)$ predice a Y . Es decir, que debe cumplir

$$g(x) = \arg \min_{h: \mathcal{X} \rightarrow \mathcal{Y}} E [L(Y, h(x)) | X = x] .$$

APRENDIZAJE ¡NO! SUPERVISADO...

EJEMPLO: NO SUPERVISADO




Figura 7: Clustering.

EJEMPLO: NO SUPERVISADO



Figura 8: Imagen satelital

EJEMPLO: NO SUPERVISADO




Figura 9: Segmentación de imágenes

NO SUPERVISADO: ¿Con qué no contamos?

Cuando hablamos de aprendizaje no supervisado con qué **NO** podemos contar,

- El output (Y), es decir, no tenemos respuestas correctas.

NO SUPERVISADO: ¿Con qué no contamos?

Cuando hablamos de aprendizaje no supervisado con qué **NO** podemos contar,

- El output (Y), es decir, no tenemos respuestas correctas.
- La función de pérdida.

No tenga dudas, es un problema más complicado.

NO SUPERVISADO: ¿Con qué no contamos?

Cuando hablamos de aprendizaje no supervisado con qué **NO** podemos contar,

- El output (Y), es decir, no tenemos respuestas correctas.
- La función de pérdida.
- En ocasiones ni siquiera una buena definición del problema que queremos resolver.

No tenga dudas, es un problema más complicado.

NO SUPERVISADO: ¿Qué podemos hacer?

Tenemos un conjunto de observaciones x_1, \dots, x_n que provienen de un elemento aleatorio X que tiene una distribución P_X .

El objetivo es inferir propiedades de P_X que no son los problemas clásicos de la estadística como aproximar posición o variabilidad.

Nuestro trabajo estará centrado en los siguientes problemas:

- Clustering.

NO SUPERVISADO: ¿Qué podemos hacer?

Tenemos un conjunto de observaciones x_1, \dots, x_n que provienen de un elemento aleatorio X que tiene una distribución P_X .

El objetivo es inferir propiedades de P_X que no son los problemas clásicos de la estadística como aproximar posición o variabilidad.

Nuestro trabajo estará centrado en los siguientes problemas:

- Clustering.
- Reducción de dimensión.

NO SUPERVISADO: ¿Qué podemos hacer?

Tenemos un conjunto de observaciones x_1, \dots, x_n que provienen de un elemento aleatorio X que tiene una distribución P_X .

El objetivo es inferir propiedades de P_X que no son los problemas clásicos de la estadística como aproximar posición o variabilidad.

Nuestro trabajo estará centrado en los siguientes problemas:

- Clustering.
- Reducción de dimensión.
- Detección de valores atípicos (outliers).

CLUSTERS

Dado un conjunto de elementos heterogéneos, los métodos de **clustering**, son técnicas que tienen como objetivo contruir grupos o **clusters** más homogéneos.

Se espera que esos nuevos conjuntos estén formados por elementos con características comunes referidas a su naturaleza. Es decir que sean similares entre sí.

CLUSTERS: CONCEPTOS

El enfoque estandar es representar la colección de objetos que tenemos como un conjunto de puntos.

Leitmotiv

Construir una **partición** del conjunto en clusters tal que puntos en el mismo cluster deben ser “*cercanos*” y puntos en diferente cluster deben estar “*alejados*”.

Todas las técnicas se centran en este objetivo que está vagamente definido.

CLUSTERS: CONCEPTOS

Sea A un conjunto y sean $\mathcal{C} = \{B_1, \dots, B_K\}$ una colección de subconjuntos de A . Decimos que \mathcal{C} es una **partición** de A , si se cumplen dos condiciones:

- \mathcal{C} es una colección de conjuntos disjuntos, es decir,

$$B_i \cap B_j = \emptyset \quad \forall 1 \leq i, j \leq K.$$

- \mathcal{C} es un cubrimiento de A , es decir,

$$A = B_1 \cup B_2 \cup \dots \cup B_K = \bigcup_{B \in \mathcal{C}} B.$$

CLUSTERS: CONCEPTOS

Sea A un conjunto y sean $\mathcal{C} = \{B_1, \dots, B_K\}$ una colección de subconjuntos de A . Decimos que \mathcal{C} es una **partición** de A , si se cumplen dos condiciones:

- \mathcal{C} es una colección de conjuntos disjuntos, es decir,

$$B_i \cap B_j = \emptyset \quad \forall 1 \leq i, j \leq K.$$

- \mathcal{C} es un cubrimiento de A , es decir,

$$A = B_1 \cup B_2 \cup \dots \cup B_K = \bigcup_{B \in \mathcal{C}} B.$$


Construir clusters es el arte de construir particiones.

Pensemos un ejemplo muy simple, consideremos el conjunto $A = \{1, 2, 3, 4, 7, 8\}$ y construyamos una partición de tres subconjuntos.

- $B_1 = \{1, 2, 4\}$.
- $B_2 = \{3, 7\}$.
- $B_3 = \{8\}$.

Es claro que $B_1 \cup B_2 \cup B_3 = A$. Además los conjuntos son disjuntos, es decir, no comparten elementos.

CLUSTERS: CONCEPTOS



AGRUPAR LOS SIMPSONS



PARTICIÓN SIMPSONS



Cuadro 1: Familia



Cuadro 2: Escuela

Si tenemos un conjunto de datos $\{x_1, \dots, x_n\}$ y queremos contruir particiones en relación al leitmotiv de la técnica de clustering vamos a necesitar:

- Entender el espacio ambiente de los datos, es decir, el conjunto más grande que los contiene.
- Formalizar el concepto de similaridad o disimilaridad entre los datos.
- Determinar el número K de particiones convenientes.

CLUSTERS: CONCEPTOS

En general los conjuntos de datos con los que vamos a trabajar van a estar contenidos en un espacio con alguna noción de métrica o disimilaridad.

CLUSTERS: CONCEPTOS

En general los conjuntos de datos con los que vamos a trabajar van a estar contenidos en un espacio con alguna noción de métrica o disimilaridad.

Dado un conjunto E , decimos que una función $d : E \times E \rightarrow [0, +\infty)$ es una **métrica** si cumple,

1. $d(x, y) = 0$ si y sólo si $x = y$.
2. $d(x, y) = d(y, x)$ para todo $x, y \in E$.
3. Dados $x, y, z \in E$ se cumple la desigualdad triangular, es decir, $d(x, y) \leq d(x, z) + d(z, y)$.

CLUSTERS: CONCEPTOS

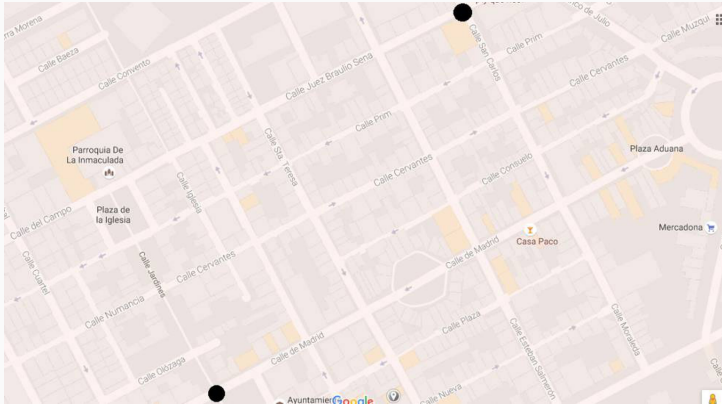
En general los conjuntos de datos con los que vamos a trabajar van a estar contenidos en un espacio con alguna noción de métrica o disimilaridad.

Dado un conjunto E , decimos que una función $d : E \times E \rightarrow [0, +\infty)$ es una **métrica** si cumple,

1. $d(x, y) = 0$ si y sólo si $x = y$.
2. $d(x, y) = d(y, x)$ para todo $x, y \in E$.
3. Dados $x, y, z \in E$ se cumple la desigualdad triangular, es decir, $d(x, y) \leq d(x, z) + d(z, y)$.

Si sólo se cumplen (1) y (2) decimos que d es una **disimilaridad**.

CLUSTERS: CONCEPTOS



Espacios de dimensión finita.

- (\mathbb{R}^p, d_2) , donde $d_2(x, y) = \|x - y\|_2 = \sqrt{\sum_{j=1}^p (x_j - y_j)^2}$.
- (\mathbb{R}^p, d_1) , donde $d_1(x, y) = \|x - y\|_1 = \sum_{j=1}^p |x_j - y_j|$.
- (\mathbb{R}^p, d_∞) , donde $d_\infty(x, y) = \|x - y\|_\infty = \max_{j=1, \dots, p} |x_j - y_j|$.

Espacios de dimensión finita.


- (\mathbb{R}^p, d_2) , donde $d_2(x, y) = \|x - y\|_2 = \sqrt{\sum_{j=1}^p (x_j - y_j)^2}$.
- (\mathbb{R}^p, d_1) , donde $d_1(x, y) = \|x - y\|_1 = \sum_{j=1}^p |x_j - y_j|$.
- (\mathbb{R}^p, d_∞) , donde $d_\infty(x, y) = \|x - y\|_\infty = \max_{j=1, \dots, p} |x_j - y_j|$.

Un ejemplo de un espacio de dimensión infinita,

$$C([0, 1], \mathbb{R}^p) = \{f : [0, 1] \rightarrow \mathbb{R}^p : f \text{ es continua}\},$$

$$d(f, g) = \sup_{t \in [0, 1]} \|f(t) - g(t)\|_2.$$

CLUSTERS: CONCEPTOS



CLUSTERS: CONCEPTOS

Determinar el número de clusters no es un problema trivial.






Figura 10: ¿Dos grupos?

CLUSTERS: CONCEPTOS

Detectar los clusters




Figura 11: ¿Cuatro grupos?

Detectar los clusters




Figura 12: ¿Seis grupos?


CLUSTERS: CONCEPTOS

Otro problema asociado a las particiones es la cantidad de particiones que se pueden hacer con pocos datos, aunque sepamos el número de clusters.

Este es un problema muy estudiado por la combinatoria: el **número de Stirling** que representa la cantidad de particiones no nulas que se pueden obtener con n elementos y k subconjuntos, $S(n, k)$ con $k \leq n$.

$$S(n, k) = S(n - 1, k - 1) + kS(n - 1, k)$$

CLUSTERS: CONCEPTOS



A nivel de métodos y algoritmos tenemos enfoques más concretos:

- Centroides.
- Aglomerativos.
- Divisivos.
- Basados en modelos generativos.
- Fundamentados en la teoría de la información.