

# Aprendizaje No Supervisado

Maestría en Ciencia de Datos

---

Lucas Fernández Piana

Primavera 2022

Universidad de San Andrés

# Análisis de Correspondencias

# Test Chi Cuadrado

---

## Definición

Una tabla de contingencia es una tabla que consiste de al menos dos filas y dos columnas para representar datos categóricos en términos de conteos o frecuencias.

## Definición

Una tabla de contingencia es una tabla que consiste de al menos dos filas y dos columnas para representar datos categóricos en términos de conteos o frecuencias.

Veamos un ejemplo ...

# TABLAS DE CONTINGENCIA

	Química	Economía	Literatura	Medicina	Paz	Física	Total
Canada	4	3	2	4	1	4	18
Francia	8	3	11	12	10	9	53
Italia	1	1	6	5	1	5	19
Alemania	24	1	8	18	5	24	80
Japón	6	0	2	3	1	11	23
Reino Unido	23	6	7	26	11	20	93
Estados Unidos	51	43	8	70	19	66	257
Rusia	4	3	5	2	3	10	27
<b>Total</b>	121	60	49	140	51	149	570

**Cuadro 1:** Premios Nobel repartidos entre los países del G8

# TABLAS DE CONTINGENCIA

	Química	Economía	Literatura	Medicina	Paz	Física	Total
Canada	4	3	2	4	1	4	18
Francia	8	3	11	12	10	9	53
Italia	1	1	6	5	1	5	19
Alemania	24	1	8	18	5	24	80
Japón	6	0	2	3	1	11	23
Reino Unido	23	6	7	26	11	20	93
Estados Unidos	51	43	8	70	19	66	257
Rusia	4	3	5	2	3	10	27
<b>Total</b>	121	60	49	140	51	149	570

**Cuadro 1:** Premios Nobel repartidos entre los países del G8

¿Existe alguna relación entre países y categorías?

# TABLAS DE CONTINGENCIA

	Química	Economía	Literatura	Medicina	Paz	Física	Total
Canada	4	3	2	4	1	4	18
Francia	8	3	11	12	10	9	53
Italia	1	1	6	5	1	5	19
Alemania	24	1	8	18	5	24	80
Japón	6	0	2	3	1	11	23
Reino Unido	23	6	7	26	11	20	93
Estados Unidos	51	43	8	70	19	66	257
Rusia	4	3	5	2	3	10	27
<b>Total</b>	121	60	49	140	51	149	570

**Cuadro 1:** Premios Nobel repartidos entre los países del G8

¿Existe alguna relación entre países y categorías?

¿Algunos países se especializan en ciertas áreas más que otros?



# TABLAS DE CONTINGENCIA

## Modelando el problema:

Tenemos una muestra de tamaño  $n$  y 2 variables cualitativas.  
Podemos resumir la información en una tabla,

$n_{11}$	$n_{12}$	$\dots$	$n_{1j}$	$\dots$	$n_{1J}$	$n_{1.}$
$n_{21}$	$n_{22}$	$\dots$	$n_{2j}$	$\dots$	$n_{2J}$	$n_{2.}$
$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
$n_{i1}$	$n_{i2}$	$\dots$	$n_{ij}$	$\dots$	$n_{iJ}$	$n_{i.}$
$\vdots$	$\vdots$		$\vdots$	$\ddots$	$\vdots$	$\vdots$
$n_{I1}$	$n_{I2}$	$\dots$	$n_{IJ}$	$\dots$	$n_{IJ}$	$n_{I.}$
$n_{.1}$	$n_{.2}$	$\dots$	$n_{.j}$	$\dots$	$n_{.J}$	$n_{..} = n$

Cuadro 2:

# TABLAS DE CONTINGENCIA

La cantidad de individuos en cada celda de la tabla tiene distribución **multinomial**, es decir se puede modelar por una tabla aleatoria  $N \sim \mathcal{M}(n, [p_{ij}]_{ij})$  donde  $p_{ij}$  es la probabilidad que una observación caiga en la fila  $i$  y la columna  $j$ .

# TABLAS DE CONTINGENCIA

La cantidad de individuos en cada celda de la tabla tiene distribución **multinomial**, es decir se puede modelar por una tabla aleatoria  $N \sim \mathcal{M}(n, [p_{ij}]_{ij})$  donde  $p_{ij}$  es la probabilidad que una observación caiga en la fila  $i$  y la columna  $j$ .

Recordemos cómo se calculaban las marginales:

$$p_j = \sum_{i=1}^I p_{ij} \text{ probabilidad de caer en la columna } j.$$

$$p_i = \sum_{j=1}^J p_{ij} \text{ probabilidad de caer en la fila } i.$$

# TABLAS DE CONTINGENCIA

$p_{11}$	$p_{12}$	$\dots$	$p_{1j}$	$\dots$	$p_{1J}$	$\mathbf{p_{1.}}$
$p_{21}$	$p_{22}$	$\dots$	$p_{2j}$	$\dots$	$p_{2J}$	$\mathbf{p_{2.}}$
$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
$p_{i1}$	$p_{i2}$	$\dots$	$p_{ij}$	$\dots$	$p_{iJ}$	$\mathbf{p_{i.}}$
$\vdots$	$\vdots$		$\vdots$	$\ddots$	$\vdots$	$\vdots$
$p_{I1}$	$p_{I2}$	$\dots$	$p_{IJ}$	$\dots$	$p_{IJ}$	$\mathbf{p_{I.}}$
$\mathbf{p_1}$	$\mathbf{p_2}$	$\dots$	$\mathbf{p_j}$	$\dots$	$\mathbf{p_J}$	$\mathbf{1}$

Cuadro 3:

Ahora podemos escribir las hipótesis para un test,

$$H_0 : p_{ij} = p_i p_j \quad \forall i, j$$

$$H_A : \exists i, j \text{ tal que } p_{ij} \neq p_i p_j$$

# TABLAS DE CONTINGENCIA

Ahora podemos escribir las hipótesis para un test,

$$H_0 : p_{ij} = p_i p_j \quad \forall i, j$$

$$H_A : \exists i, j \text{ tal que } p_{ij} \neq p_i p_j$$

Bajo  $H_0$  el estimador de máxima verosimilitud de  $p_{ij}$  es

$$\hat{p}_{ij} = f_{i.} f_{.j},$$

donde,

$$f_{i.} = \frac{n_{i.}}{n} \quad \text{y} \quad f_{.j} = \frac{n_{.j}}{n}$$

# TABLAS DE CONTINGENCIA

Definimos las siguientes cantidades,

- **Observados:**  $O_{ij} = n_{ij} = nf_{ij}$  la cantidad de individuos que caen en el lugar  $i, j$  de la tabla.
- **Esperados:**  $E_{ij} = n\hat{p}_{ij} = \frac{n_{i.}n_{.j}}{n}$  la cantidad de individuos esperados bajo  $H_0$  que caigan en el lugar  $i, j$  de la tabla.

# TABLAS DE CONTINGENCIA

Definimos las siguientes cantidades,

- **Observados:**  $O_{ij} = n_{ij} = nf_{ij}$  la cantidad de individuos que caen en el lugar  $i, j$  de la tabla.
- **Esperados:**  $E_{ij} = n\hat{p}_{ij} = \frac{n_{i.}n_{.j}}{n}$  la cantidad de individuos esperados bajo  $H_0$  que caigan en el lugar  $i, j$  de la tabla.

Luego, el estadístico del test,

$$\chi = \sum_{i=1}^I \sum_{j=1}^J \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

Bajo  $H_0$ ,  $\chi \sim \chi^2_{(I-1)(J-1)}$  asintótica.



Observemos

$$\begin{aligned}\chi^2 &= \sum_{i=1}^I \sum_{j=1}^J \frac{(O_{ij} - E_{ij})^2}{E_{ij}} = \sum_{i=1}^I \sum_{j=1}^J \left( nf_{ij} - \frac{n_{i.}n_{.j}}{n} \right)^2 \frac{n}{n_{i.}n_{.j}} = \\ &= \sum_{i=1}^I \sum_{j=1}^J \left( nf_{ij} - n \frac{n_{i.}n_{.j}}{n^2} \right)^2 \frac{n}{n_{i.}n_{.j}} = \sum_{i=1}^I \sum_{j=1}^J n(f_{ij} - f_{i.}f_{.j})^2 \frac{n^2}{n_{i.}n_{.j}} \\ \chi^2 &= n \sum_{i=1}^I \sum_{j=1}^J (f_{ij} - f_{i.}f_{.j})^2 \frac{1}{f_{i.}f_{.j}} = n\Phi^2\end{aligned}$$

$\Phi^2$  lleva el nombre de **inercia**.

Es posible tener una escritura matricial de la inercia.

Llamemos  $N = [n_{ij}]$  y  $P = \frac{N}{n} = [f_{ij}]$ . Consideremos los vectores,

$$r = P \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} = \begin{pmatrix} f_{1.} \\ \vdots \\ f_{l.} \end{pmatrix} \quad \text{y} \quad c = P^t \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} = \begin{pmatrix} f_{.1} \\ \vdots \\ f_{.j} \end{pmatrix}$$

Construimos a partir de  $r$  y  $c$  las matrices diagonales

$D_r = \text{diag}(r)$  y  $D_c = \text{diag}(c)$ .

Observar

$$rc^t = \begin{pmatrix} f_{1.} \\ \vdots \\ f_{l.} \end{pmatrix} \begin{pmatrix} f_{.1} & \dots & f_{.j} \end{pmatrix} = \begin{pmatrix} f_{1.f.1} & \dots & f_{1.f.j} \\ \vdots & & \vdots \\ f_{l.f.1} & \dots & f_{l.f.j} \end{pmatrix}$$

$$P - rc^t = \begin{pmatrix} f_{11} - f_{1.f.1} & \dots & f_{1j} - f_{1.f.j} \\ \vdots & & \vdots \\ f_{l1} - f_{l.f.1} & \dots & f_{lj} - f_{l.f.j} \end{pmatrix}$$

Observar

$$rc^t = \begin{pmatrix} f_{1.} \\ \vdots \\ f_{l.} \end{pmatrix} \begin{pmatrix} f_{.1} & \dots & f_{.j} \end{pmatrix} = \begin{pmatrix} f_{1.}f_{.1} & \dots & f_{1.}f_{.j} \\ \vdots & & \vdots \\ f_{l.}f_{.1} & \dots & f_{l.}f_{.j} \end{pmatrix}$$
$$P - rc^t = \begin{pmatrix} f_{11} - f_{1.}f_{.1} & \dots & f_{1j} - f_{1.}f_{.j} \\ \vdots & & \vdots \\ f_{l1} - f_{l.}f_{.1} & \dots & f_{lj} - f_{l.}f_{.j} \end{pmatrix}$$

$P - rc^t$  contiene en cada fila la diferencia entre la frecuencia observada y la frecuencia estimada bajo independencia.

Más aún, si hacen las cuentas, podemos expresar la inercia como

$$\Phi^2 = \text{traza} (D_r^{-1}(P - rc^t)D_c^{-1}(P - rc^t)^t)$$

Más aún, si hacen las cuentas, podemos expresar la inercia como

$$\Phi^2 = \text{traza} (D_r^{-1}(P - rc^t)D_c^{-1}(P - rc^t)^t)$$

**Objetivo:** encontrar una representación en dimensión baja de las filas de  $(P - rc^t)$  que resguarde la inercia lo más posible.

Más aún, si hacen las cuentas, podemos expresar la inercia como

$$\Phi^2 = \text{traza} (D_r^{-1}(P - rc^t)D_c^{-1}(P - rc^t)^t)$$

**Objetivo:** encontrar una representación en dimensión baja de las filas de  $(P - rc^t)$  que resguarde la inercia lo más posible.

**Observación:** la inercia juega el mismo papel que la variabilidad en el caso de componentes principales.

Para eso vamos a utilizar una técnica que se llama **GSVD**:  
Generalized **Singular Value** Descomposition.



Para eso vamos a utilizar una técnica que se llama **GSVD**:  
**Generalized Singular Value Decomposition.**

¿De qué se trata?

Para eso vamos a utilizar una técnica que se llama **GSVD**: Generalized Singular **Value** Descomposition.

¿De qué se trata?

Sean las matrices  $\Omega \in \mathbb{R}^{I \times I}$  y  $\Psi \in \mathbb{R}^{J \times J}$  simétricas y definidas positivas. Dada la matriz  $A \in \mathbb{R}^{I \times J}$  podemos factorizarla como

$$A = U D_{\alpha} V = \sum_{k=1}^K \alpha_k U_k V_k^t,$$

donde  $K$  es el rango de  $A$ ,  $U^t \Omega U = I_{K \times K}$ ,  $V^t \Psi V = I_{K \times K}$  y  $D_{\alpha} = \text{diag}(\alpha_1, \dots, \alpha_K)$  con  $\alpha_1 \geq \dots \geq \alpha_K > 0$ .

Observemos dos cosas importantes:

Observemos dos cosas importantes:

(1) Las columnas de  $U$  y  $V$  son ortogonales para el producto interno dado por  $\Omega$  y  $\Psi$ .

Observemos dos cosas importantes:

(1) Las columnas de  $U$  y  $V$  son ortogonales para el producto interno dado por  $\Omega$  y  $\Psi$ .

(2) La descomposición GSVD  $A = \sum_{k=1}^K \alpha_k u_k v_k^t$  nos permite escribir las filas de la matriz  $A$  como combinación lineal de las columnas de  $V$ . Es decir, si llamamos  $A_1, \dots, A_l$  a las filas de la matriz  $A$ ,

$$A_1 = \alpha_1 u_1^1 v_1 + \alpha_2 u_2^1 v_2 + \dots + \alpha_K u_K^1 v_K$$

...

$$A_l = \alpha_1 u_1^l v_1 + \alpha_2 u_2^l v_2 + \dots + \alpha_K u_K^l v_K$$

## GSVD EN NUESTRO PROBLEMA

La técnica GSVD resuelve nuestro problemas, es cuestión de saber quién es quién.

- $A = P - rc^t$
- $\Omega = D_r^{-1}$
- $\Psi = D_c^{-1}$

# GSVD EN NUESTRO PROBLEMA

La técnica GSVD resuelve nuestros problemas, es cuestión de saber quién es quién.

- $A = P - rc^t$
- $\Omega = D_r^{-1}$
- $\Psi = D_c^{-1}$

Aplico GSVD y consigo  $U, V$  tales que

$$P - rc^t = \sum_{k=1}^K \alpha_k u_k v_k^t.$$

Es decir, escribo las filas de  $P - rc^t$  como combinación lineal de las columnas de  $V$  que son ortogonales con respecto al producto interno dado por  $D_c^{-1}$ .

Finalmente para tener una representación que se pueda dibujar truncamos la suma en  $K^* = 2$  o  $3$ .



Finalmente para tener una representación que se pueda dibujar truncamos la suma en  $K^* = 2$  o  $3$ .

¿Cómo controlamos lo que perdemos al truncar?

Es posible probar que

$$\Phi^2 = \text{traza} (D_r^{-1}(P - rc^t)D_c^{-1}(P - rc^t)^t)) = \sum_{k=1}^K \alpha_k^2.$$

Finalmente para tener una representación que se pueda dibujar truncamos la suma en  $K^* = 2$  o  $3$ .

¿Cómo controlamos lo que perdemos al truncar?

Es posible probar que

$$\Phi^2 = \text{traza} (D_r^{-1}(P - rc^t)D_c^{-1}(P - rc^t)^t)) = \sum_{k=1}^K \alpha_k^2.$$

Procedemos parecido a las componentes principales  
comparamos la cantidad de inercia que juntamos truncando  
en  $K^*$ .

El mismo análisis se puede hacer para las columnas.

Simplemente debemos transponer la matriz  $P$  y resulta que la inercia coincide.

COFFEE BREAK!

